



Universidade Do Minho

2023/2024

Aprendizagem Automática em Sistemas Empresariais

Grupo 2

Realizado por:

Maria Inês Monteiro Lima a96271

Isabel Filipa Sousa Pereira PG53885

Ana Luísa de Barros Silva PG53634

Leonor Pedro Seabra Mucambe PG5399

ÍNDICE

1.	Business Understanding.....	1
1.1.	Determinar Objetivos de Negócio	1
1.1.1.	Background	1
1.1.2.	Objetivos de negócio	1
1.1.3.	Critérios de Sucesso de Negócio	1
1.2.	Avaliação da situação	1
1.2.1.	Inventário dos Recursos.....	1
1.2.2.	Requisitos, pressupostos e restrições.....	2
1.2.3.	Riscos e contingências	2
1.2.4.	Terminologia	3
1.2.5.	Custos e benefícios	3
1.3.	Determinar Metas de Data Mining.....	3
1.3.1.	Objetivos de Data Mining	3
1.3.2.	Critérios de sucesso de Data Mining.....	4
1.4.	Produzir Plano de projeto.....	4
1.4.1.	Planeamento do projeto	4
1.4.2.	Avaliação inicial de ferramentas e técnicas	4
2.	Data Understanding	6
2.1.	Recolha Inicial dos dados.....	6
2.2.	Descrição dos Dados.....	6
2.2.1.	Dicionário de Dados	6
2.3.	Explorações de Dados.....	7
2.3.1.	Campos numéricos	7
2.3.2.	Campos Categóricos	9
2.3.3.	Outliers	9
2.3.4.	Estudo de Correlação.....	10
2.4.	Verificar a Qualidade dos Dados	11
2.4.1.	Resultados da avaliação.....	22
3.	Data Preparation.....	22
3.1.	Seleção dos Dados	22
3.2.	Limpeza dos dados	23
3.3.	Construção dos Dados	24
3.4.	Integração dos Dados	24
3.5.	Formatação dos Dados	25
4.	Modeling	25

4.1.	Selecionar Técnicas de Modelação.....	25
4.2.	Gerar Modelos de teste.....	26
4.3.	Construir modelo.....	26
4.4.	Avaliar modelo.....	29
	CENÁRIO 1.....	30
	CENÁRIO 2.....	31
	CENÁRIO 3.....	32
	CENÁRIO 4.....	33
4.5.	Selecionar o melhor modelo	33
5.	Evaluation	34
5.1.	Avaliação de Resultados	34
5.2.	Revisão do processos.....	35
5.3.	Determinação dos próximos passos	35
	Referências	36
	Anexo.....	37

ÍNDICE DE FIGURAS

Figura 1 - Diagrama de Gantt.....	4
Figura 2 - Média + desvio padrão	7
Figura 3 - Mínimo e Máximo.....	8
Figura 4 - Moda e Mediana.....	8
Figura 5 - Percentis	9
Figura 6 – Histograma.....	9
Figura 7-Outliers	10
Figura 8-Heatmap	11
Figura 9- Sem outliers	23
Figura 10- Parâmetros associados a Random Forest.....	26
Figura 11- Parâmetros associados a Decision Tree	27
Figura 12 -Parâmetros associados às redes neuronais.....	27
Figura 13-Parâmetros associados a Naive Baves.....	28
Figura 14- Parâmetros associados a SVM.....	28
Figura 15- Escolha do Modelo	34
Figura 16 - Código média + desvio.....	37
Figura 17- Código mínimo e máximo	37
Figura 18- Código moda e mediana	37
Figura 19- Código percentis	37
Figura 20 - Código de substituição dos valores numéricos por categorias descritivas na coluna 'price_range' ..	38
Figura 21 - Seleção dos campos categóricos do DataFrame 'df'	38
Figura 22- Criar um conjunto de gráficos de barras que representam a distribuição dos preços em diferentes categorias de preço de um DataFrame	38
Figura 23- Código do HeatMap	38
Figura 24 - Código dos Outliers.....	39
Figura 25- Cenário 1.....	39
Figura 26- Cenário 2.....	40
Figura 27- Cenário 3.....	40
Figura 28- Cenário 4.....	41
Figura 29 - Modelação de Random Forest com a técnica de validação Cross-Validation.....	41
Figura 30- Modelação de Decision Treen com a técnica de validação Cross-Validation.....	41
Figura 31 - Modelação de Redes neuronais com a técnica de validação Cross-Validation	42
Figura 32 - Modelação de Naive Bayes com a técnica de validação Cross-Validation	42
Figura 33 - Modelação de SVM com a técnica de validação Cross-Validation	42
Figura 34 - Árvore de decisão do cenário 1	43

Figura 35- Árvore de decisão do cenário 2	43
Figura 36- Árvore de decisão do cenário 3	43
Figura 37- Árvore de decisão do cenário 4	43

ÍNDICE DE TABELAS

Tabela 1 - Inventário dos recursos.....	2
Tabela 2 - Riscos e contingências	3
Tabela 3 - Avaliação inicial de ferramentas e técnicas	5
Tabela 4 - Dicionário de Dados	7
Tabela 5- Qualidade de Dados.....	22
Tabela 6- Cenários	24
Tabela 7 – Conclusão dos cenários	24
Tabela 8- Formatação dos dados.....	25
Tabela 9- Gerar modelos de Teste.....	26
Tabela 10- Técnicas para Cenário 1	30
Tabela 12- Técnicas para Cenário 2	31
Tabela 14- Técnicas para Cenário 3	32
Tabela 16- Técnicas para cenário 4.....	33

1. BUSINESS UNDERSTANDING

Esta etapa é o ponto de partida importante num projeto de análise de dados. Nesta fase, o foco principal é definir claramente os objetivos do projeto, garantindo que o resultado seja de alta qualidade e atenda às necessidades. Para alcançar esse objetivo, são realizadas as seguintes etapas:

- Determinar objetivos de negócio;
- Descrição da situação;
- Determinar objetivos de *Data Mining*;
- Produzir o plano de projeto.

1.1. DETERMINAR OBJETIVOS DE NEGÓCIO

1.1.1. BACKGROUND

No início do projeto, a informação que obtivemos acerca da situação de negócio da organização é que se centra no fabrico de dispositivos móveis. Dispositivos estes de diferentes modelos e características.

Relativamente aos *datasets*, a informação que nos é fornecida contém diversas características de cada dispositivo, tais como, bateria, velocidade, memória, entre outras.

1.1.2. OBJETIVOS DE NEGÓCIO

O principal objetivo de negócio consiste em ter a capacidade de permitir fazer uma estimativa do preço de um telemóvel com base nas suas características. Com esta informação, o Bob poderá ajustar os preços dos seus telemóveis de forma a estimar o preço de venda com um erro inferior a 5%, ou seja, permitindo uma margem de erro de até 5%, melhorando assim a competitividade no mercado de telemóveis.

1.1.3. CRITÉRIOS DE SUCESSO DE NEGÓCIO

O critério de sucesso é uma medida fundamental que avalia o desempenho e a eficácia de um projeto com base nos objetivos de negócio estabelecidos. No contexto específico deste projeto, o critério de sucesso de negócio é alcançar uma precisão na estimativa de preço com um erro inferior a 5%. Isso significa que a análise de dados deve ser capaz de prever o preço de venda dos telemóveis com uma margem de erro de até 5%. O sucesso do projeto será determinado pela capacidade de fornecer essa estimativa precisa, permitindo que o Bob ajuste os preços dos seus telemóveis de forma eficaz, atendendo às expectativas do cliente e mantendo uma margem de erro aceitável.

1.2. AVALIAÇÃO DA SITUAÇÃO

1.2.1. INVENTÁRIO DOS RECURSOS

O inventário dos recursos desempenha um papel crucial na avaliação e enumeração dos recursos necessários para uma análise de dados eficaz. Consoante a metodologia que vamos adotar, CRISP-DM, é necessário identificar diferentes tipos de recursos, como pessoas, dados, hardware e software.

Recurso	Descrição
Pessoas	A equipa de trabalho é constituída por 4 elementos, com alguns conhecimentos no que diz respeito a tratamento e análise de dados.
Dados	Em relação aos dados que serão tratados foram disponibilizados 3 ficheiros em formato csv pelo docente.
Hardware	A nível de hardware serão utilizados os computadores pessoais de cada elemento da equipa para tratar do processamento de dados. Estas máquinas deverão ser capazes de suportar todas as operações necessárias durante o desenvolvimento do projeto.
Software	A nível de software a equipa vai utilizar: <i>Tableau</i> , <i>Talend</i> , <i>Jupyter Notebook</i> , <i>Microsoft Office Word</i> , <i>Microsoft Office Excel</i> e <i>ProjectLibre</i> .

Tabela 1 - Inventário dos recursos

1.2.2. REQUISITOS, PRESSUPOSTOS E RESTRIÇÕES

Requisitos:

- Data de Entrega do projeto: 11 de dezembro de 2023;
- Qualidade e compreensão dos resultados;
- Utilização da Metodologia CRISP-DM;
- Utilização uma ferramenta de Data *Mining*;
- Utilização dos *datasets* fornecidos pelo docente;

Pressupostos:

- É importante que os dados recolhidos estejam completos, precisos e fiáveis. Caso este pressuposto não seja cumprido, a análise e as previsões resultantes podem ser comprometidas;
- A equipa terá os conhecimentos necessários para executar todas as tarefas do projeto e uma participação eficaz e integrada durante a sua execução;
- O mercado de telemóveis não sofrerá mudanças bruscas durante o período de recolha e análise de dados.

Restrições:

- Tempo limitado para a realização do projeto;
- Contexto de negócio desconhecido;
- Pouca experiência na utilização da ferramenta Data *Mining*;
- Complexidade na Integração de dados.

1.2.3. RISCOS E CONTINGÊNCIAS

No contexto do nosso projeto, apresentamos na tabela abaixo uma lista de possíveis riscos que podem surgir durante a análise e mineração de dados. Cada risco está associado a um plano de contingência, ou seja, uma estratégia definida para superar os obstáculos que possam surgir durante a execução do projeto. O nosso objetivo é antecipar e estar preparado para lidar com quaisquer dificuldades que possam surgir ao longo do processo de análise de dados.

Riscos	Plano de contingência
Dificuldade na utilização das ferramentas	Procurar e consultar documentação das ferramentas a utilizar e partilhar a dificuldade com os restantes elementos do grupo. Caso não seja suficiente, pedir ajuda ao docente.
Dificuldade na análise dos dados	A equipa deve reunir para discutir e analisar os dados e esclarecer dúvidas com o docente caso necessário.
Má qualidade dos dados	Os dados devem ser analisados com bastante cuidado e de forma exaustiva para evitar possíveis problemas nas próximas fases.
Falta de comunicação dentro da equipa	Marcar reuniões semanais para garantir que todos os elementos da equipa estão a par e a realizar as suas tarefas.
Dificuldade na compreensão da metodologia CRISP-DM	Todos os elementos devem reler toda informação dada pelo docente e tentar compreender o problema. No caso de persistir, comunicar ao docente a dúvida.
Objetivos de negócio e de Data Mining mal definidos	A equipa deverá reavaliar e reestruturar o projeto.
Atraso no desenvolvimento do projeto	Redistribuir melhor as tarefas e trabalhar horas extras de forma a cumprir os prazos estabelecidos.

Tabela 2 - Riscos e contingências

1.2.4. TERMINOLOGIA

CRISP-DM: A metodologia CRISP-DM (Cross-Industry Standard Process for Data Mining) é utilizada no desenvolvimento e na implementação de soluções com o objetivo de obter sucesso em projetos analíticos e preditivos. Utilizada para transformar dados em conhecimento.

Data-Mining: é o processo utilizado para identificar padrões e extrair informações úteis a partir de um grande conjunto de dados desorganizados. Explora os dados de forma a encontrar padrões, como regras de associação ou sequências temporais, que podem ser posteriormente utilizados para identificar oportunidades, otimizar operações e impulsionar o sucesso das empresas.

Dataset: conjunto de dados organizados em linhas e colunas, onde cada linha representa um acontecimento e cada coluna representa uma variável.

1.2.5. CUSTOS E BENEFÍCIOS

O projeto em questão não terá qualquer tipo de custo associados, visto que o mesmo está inserido no âmbito de uma unidade curricular, sendo um projeto académico. Ao nível de benefícios é esperado que este projeto contribua para a aprendizagem e aquisição de conhecimento por parte da equipa de trabalho.

1.3. DETERMINAR METAS DE DATA MINING

1.3.1. OBJETIVOS DE DATA MINING

No contexto do projeto de Data Mining, o principal objetivo é desenvolver um modelo preditivo que ajude Bob a estimar a gama de preço dos seus telemóveis com base nas informações recolhidas no conjunto de dados fornecidos pelo docente. Este modelo deve identificar relações ou padrões nos dados que relacionem as características dos telemóveis (como a capacidade da bateria, a velocidade do processador, a presença de dois

cartões SIM, a câmara frontal, a compatibilidade com redes 4G, a memória interna, a espessura, o peso, o número de núcleos do processador) com a gama de preço, permitindo a classificação dos telemóveis em categorias de preço.

1.3.2. CRITÉRIOS DE SUCESSO DE DATA MINING

Os critérios de sucesso de *Data Mining* diz respeito à "percentagem de acuidade" representa o quão bem o modelo é capaz de prever a gama de preço dos telemóveis com base nas características fornecidas. Uma alta percentagem de acuidade, 95%, indica que o modelo classifica corretamente 95% dos telemóveis nas categorias de preço.

1.4. PRODUZIR PLANO DE PROJETO

1.4.1. PLANEAMENTO DO PROJETO

O Diagrama de *Gantt* é uma ferramenta essencial para visualizar e gerir o nosso projeto. Ele oferece uma visão organizada das tarefas, prazos e interdependências. Este diagrama foi criado para ajudar a monitorizar o progresso, identificar áreas críticas e assegurar uma gestão eficiente das atividades do projeto.

Nome	Duração	Início	Fim	Antecessores	Nomes dos Recursos
Projeto	76 dias	25-09-2023 8:00	08-01-2024 17:00		
Análise da metodologia CRISP-DM	3 dias	25-09-2023 8:00	27-09-2023 17:00		Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Leitura e análise do enunciado	2 dias	28-09-2023 8:00	29-09-2023 17:00	2	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Business Understanding	9 dias	09-10-2023 8:00	19-10-2023 17:00		
Determinar Objetivos de Negócio	1 dia	09-10-2023 8:00	09-10-2023 17:00	3	Filipa Pereira;Inês Lima
Avaliar a situação Atual	3 dias	10-10-2023 8:00	12-10-2023 17:00	5	Leonor Mucambe
Determinar Metas de Data Mining	3 dias	13-10-2023 8:00	17-10-2023 17:00	6	Luisa Silva
Produzir Plano de Projeto	2 dias	18-10-2023 8:00	19-10-2023 17:00	7	Inês Lima
Data Understanding	20 dias	20-10-2023 8:00	16-11-2023 17:00	4	
Aquisição Inicial de Dados	3 dias	20-10-2023 8:00	24-10-2023 17:00	8	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Descrição e Análise de Dados	5 dias	25-10-2023 8:00	31-10-2023 17:00	10	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Exploração dos dados adquiridos	7 dias	01-11-2023 8:00	09-11-2023 17:00	11	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Verificação da qualidade de dados	5 dias	10-11-2023 8:00	16-11-2023 17:00	12	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Data Preparation	15 dias	20-11-2023 8:00	08-12-2023 17:00	9	
Seleção dos Dados	2 dias	20-11-2023 8:00	21-11-2023 17:00	13	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Limpeza dos Dados	3 dias	22-11-2023 8:00	24-11-2023 17:00	15	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Construção dos Dados	4 dias	27-11-2023 8:00	30-11-2023 17:00	16	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Integração dos Dados	3 dias	01-12-2023 8:00	05-12-2023 17:00	17	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Formatação dos Dados	3 dias	06-12-2023 8:00	08-12-2023 17:00	18	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Modeling	5 dias	11-12-2023 8:00	15-12-2023 17:00	14	
Seleção das Técnicas de Modelação	1 dia	11-12-2023 8:00	11-12-2023 17:00	19	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Criação de uma Concepção de Test	2 dias	12-12-2023 8:00	13-12-2023 17:00	21	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Construção do Modelo	1 dia	14-12-2023 8:00	14-12-2023 17:00	22	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Revisão do Modelo	1 dia	15-12-2023 8:00	15-12-2023 17:00	23	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Evaluation	8 dias	18-12-2023 8:00	27-12-2023 17:00	20	
Avaliação dos resultados	2 dias	18-12-2023 8:00	19-12-2023 17:00	24	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Revisão do processo	3 dias	20-12-2023 8:00	22-12-2023 17:00	26	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Determinar os próximos passos	3 dias	25-12-2023 8:00	27-12-2023 17:00	27	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Implementation	8 dias	28-12-2023 8:00	08-01-2024 17:00	25	
Reuniao de equipa	1 dia	28-12-2023 8:00	28-12-2023 17:00	28	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Monitorização e manutenção	2 dias	29-12-2023 8:00	01-01-2024 17:00	30	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Elaboração do relatório final	2 dias	02-01-2024 8:00	03-01-2024 17:00	31	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Revisão do relatório	2 dias	04-01-2024 8:00	05-01-2024 17:00	32	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva
Entrega Final	1 dia	08-01-2024 8:00	08-01-2024 17:00	33	Filipa Pereira;Inês Lima;Leonor Mucambe;Luisa Silva

Figura 1 - Diagrama de Gantt

1.4.2. AVALIAÇÃO INICIAL DE FERRAMENTAS E TÉCNICAS

A tabela abaixo apresenta uma avaliação inicial das ferramentas e técnicas a serem utilizadas no projeto, descrevendo as suas funcionalidades.

Ícone	Nome	Funcionalidades
	Microsoft Office Word	Ferramenta de processamento de texto ideal para elaborar os relatórios, seguindo as convenções de formatação e estilo apropriadas.
	Microsoft Office Excel	Ferramenta que será utilizada para operações de suporte à análise de dados.
	Project Libre	Aplicação de software usada para criar e gerir gráficos de <i>Gantt</i> , que são usados para planear e acompanhar o progresso do projeto.
	Discord	Ferramenta utilizada para as reuniões semanais online da nossa equipa, promovendo uma boa comunicação e entreaajuda.
	Talend	Ferramenta de integração de dados que nos irá ajudar a limpar e validar os mesmos.
	Jupyter Notebook	Plataforma interativa de código aberto que iremos utilizar para análise, exploração e visualização de dados.
	Python	Linguagem de programação versátil que planeamos usar neste projeto, através do ambiente interativo do <i>Jupyter</i> , para realizar análises e desenvolver soluções.
	Google Chrome	Motor de pesquisa que permite fazer pesquisas na internet e também aceder ao <i>dataset</i> que está disponível no <i>Kaggle</i> .
	VisualStudio Code	Editor de código-fonte usado para tratamento de dados.
	RapidMiner	Plataforma de ciência de dados e análise preditiva, usada para preparar dados e criar modelos de machine learning de forma intuitiva.
	Tableau	Ferramenta de visualização de dados que transforma informações em gráficos interativos e dashboards para facilitar a análise e interpretação de dados.

Tabela 3 - Avaliação inicial de ferramentas e técnicas

2. DATA UNDERSTANDING

2.1. RECOLHA INICIAL DOS DADOS

Para o desenvolvimento deste projeto, a equipa começou por descarregar o *dataset* disponibilizado, de forma a fazer uma análise correta e uma melhor compreensão dos dados.

O *dataset* utilizado para este projeto foi o “*Train*”, que descreve as características de vários telemóveis. É um ficheiro CSV, e é constituído por 1600 linhas e 21 colunas relativas aos atributos.

2.2. DESCRIÇÃO DOS DADOS

2.2.1. DICIONÁRIO DE DADOS

Para entender melhor o significado de cada atributo, construímos uma tabela para entender e compreender os dados.

Atributo	Descrição	Formato	Tipo de atributo
Battery_power	Bateria telemóvel	INT	Numérico
Blue	Cor do telemóvel	BOOLEAN	Categórico
Clock_speed	Velocidade com que o microprocessador executa instruções	DOUBLE	Numérico
Dual_sim	Se o telemóvel permite usar dois cartões SIM	BOOLEAN	Categórico
fc	Mega pixels da câmara frontal	INT	Numérico
For_g	Se o telemóvel tem 4G ou não	BOOLEAN	Categórico
Int_memory	Memória interna	INT	Numérico
M_dep	Espessura do telemóvel em cm	DOUBLE	Numérico
Mobile_wt	Peso do telemóvel	INT	Numérico
N_cores	Número de cores do processador	INT	Numérico
pc	Mega pixels da câmara principal	INT	Numérico
Px_height	Número de pixels verticais que o ecrã do telemóvel tem	INT	Numérico
Px_width	Número de pixels na horizontal que o ecrã do telemóvel tem	INT	Numérico

Ram	Quantidade de RAM (<i>Random Access Memory</i>) no telemóvel	INT	Numérico
Sc_h	Altura do ecrã do telemóvel	INT	Numérico
Sc_w	Largura do ecrã do telemóvel	INT	Numérico
Talk_time	Tempo máximo que a bateria de um telemóvel pode durar durante uma chamada telefónica	INT	Numérico
Three_g	Se o telemóvel é compatível com a tecnologia de rede 3G e se consegue conectar a rede 3G para aceder a internet e fazer chamadas telefónicas	BOOLEAN	Categórico
Touch_screen	Se o telemóvel tem ecrã tátil ou não	BOOLEAN	Categórico
wifi	Se o telemóvel tem wi-fi ou não	BOOLEAN	Categórico
Price_range	Faixa de preço na qual o telemóvel esta disponível (0: custo baixo, 1: Custo médio, 2: Custo elevado, 3: Custo muito elevado)	INT	Categórico

Tabela 4 - Dicionário de Dados

2.3. EXPLORAÇÕES DE DADOS

Para a exploração de dados, identificamos e analisamos as características de cada atributo e se existissem irregularidades nos mesmos. Para isto, utilizamos a ferramenta *Jupyter* no *VSCode* onde aplicamos a linguagem *Python*. Conseguimos assim realizar estatísticas básicas assim como ter uma análise mais visual. O código desenvolvido encontra-se em anexo.

2.3.1. CAMPOS NUMÉRICOS

– Média + desvio padrão

```

battery_power    1681.222232
clock_speed      2.335884
fc               8.747482
int_memory       49.983372
m_dep            0.791724
mobile_wt        175.510779
n_cores          6.779798
pc               16.084792
px_height        1092.567051
px_width         1687.045393
ram              3197.986380
sc_h             16.573768
sc_w             10.096968
talk_time        16.525109

```

Figura 2 - Média + desvio padrão

— [Mínimo e Máximo](#)




Figura 3 - Mínimo e Máximo

— [Moda e Mediana](#)




Figura 4 - Moda e Mediana

— [Percentis](#)




Figura 5 - Percentis

2.3.2. CAMPOS CATEGÓRICOS

O histograma da figura 6 baseia-se em quatro gráficos de barras, um para cada categoria de preço presente nos dados. Cada gráfico mostra a percentagem de preços para diferentes características (eixo x) em relação ao total de cada categoria de preço. As barras estão ordenadas da maior para a menor percentagem de preço, e cores diferentes representam cada característica. Esta representação visual ajuda a comparar a frequência relativa de preços entre diferentes características em cada faixa de preço.

O código do seu desenvolvimento no *VSCode* está em anexo.

— [Histograma](#)




Figura 6 – Histograma

2.3.3. OUTLIERS


Outliers são valores atípicos provenientes de erros na recolha de dados ou de eventos raros. São dados que se distanciam significativamente de todos os outros, valores que fogem da normalidade e que podem causar desequilíbrio nos resultados obtidos. A sua presença pode, ou não, ter um impacto negativo na análise de dados, é importante identificá-los e avaliar para garantir uma análise precisa e confiável.

De modo a identificar os *outliers*, utilizamos a ferramenta boxplot. Este é uma ferramenta gráfica que permite visualizar a distribuição e a dispersão dos dados através de quartis.

A caixa (box) no centro representa o intervalo interquartil (IQR), que abrange o segundo e terceiro quartis (Q2 e Q3), a linha no meio da caixa indica a mediana (Q2). As "antenas" estendem-se a partir da caixa até os valores mínimos e máximos dentro de 1,5 vezes o IQR e os pontos representam os *outliers*.

A equipa foi capaz de encontrar *outliers* em 2 variáveis numéricas:

- "fc"
- "px_height"




Outliers na coluna 'fc':

25	18
42	18
117	18
138	18
241	18
260	17
322	18
505	18
815	18
898	17
1337	17
1550	18

Outliers na coluna 'px_height':

457	1960
835	1949

Figura 7-Outliers



Na coluna "fc" os *outliers* são os valores superiores a 16 e na coluna "px_height" são todos superiores a 1949. Da análise do gráfico dos *outliers* tanto do atributo "fc" e do atributo "px_height", os *outliers* representam uma minoria dos dados, quase insignificante. Assim, a equipa decidiu eliminar os *outliers* deste atributo pois a sua ausência não afetará a análise.

2.3.4. ESTUDO DE CORRELAÇÃO

- [Heatmap](#)

O heatmap ou mapa de calor, é uma forma de visualização de dados que associa cores à intensidade da variável mostrada. Num heatmap de correlação a cor de cada elemento indica a magnitude da correlação entre duas variáveis.










Figura 8-Heatmap



Os valores estão limitados no intervalo de -1 até 1, sendo que os valores positivos estão associados a correlações positivas (ou seja, quando uma variável aumenta, a outra também aumenta), enquanto os valores negativos estão associados a correlações negativas, que representa uma correlação inversamente proporcional (quando uma variável aumenta, a outra diminui). Assim, os valores próximos de 0 indicam correlações fracas e valores próximos de +/-1 indicam correlações fortes.



2.4. VERIFICAR A QUALIDADE DOS DADOS







A verificação da qualidade de dados é essencial para garantir a precisão e confiabilidade das informações. Utilizando o Talend, é possível analisar minuciosamente cada atributo, identificando inconsistências, valores nulos ou duplicados. Esta abordagem detalhada assegura a conformidade com os padrões estabelecidos e aumenta a confiança nos dados, sendo fundamental para tomada de decisões precisas e análises confiáveis.



Atributo	Análise	Análise no <i>talend</i>
Battery_power	Depois de elaborada a análise geral à coluna «battery_power», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 976 valores distintos dos quais 536 são únicos e 440 são duplicados. Através da análise da frequência de valor, percebe-se que a capacidade da bateria mais frequente é a 1872, seguido da 1589. Através da análise do padrão de frequência, percebe-se que a maioria das capacidades das baterias é constituída por 4 dígitos e uma menor parte por 3 dígitos.	 Simple Statistics  
blue	Depois de elaborada a análise geral à coluna «blue», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 2 valores distintos e esses 2 valores são duplicados. Através da análise da frequência de valor, percebe-se que a frequência dos valores 0 e 1 está balanceada. Através da análise do padrão de frequência, percebe-se que todos os valores são constituídos apenas por um dígito.	 Simple Statistics  







Clock_speed	Depois de elaborada a análise geral à coluna «clock_speed», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 26 valores distintos dos quais os 26 são duplicados. Através da análise da frequência de valor, percebe-se que o clock speed mais frequente é 0.5. Através da análise do padrão de frequência, percebe-se que todos os valores de clock speed são números decimais.	Simple Statistics <table><tr><th>Category</th><th>Count</th></tr><tr><td>Row Count</td><td>1600</td></tr><tr><td>Null Count</td><td>0</td></tr><tr><td>Distinct Count</td><td>26</td></tr><tr><td>Unique Count</td><td>0</td></tr><tr><td>Duplicate Count</td><td>26</td></tr></table> Frequency of Values <table><tr><th>Value</th><th>Count</th></tr><tr><td>0.5</td><td>325</td></tr><tr><td>2.8</td><td>60</td></tr><tr><td>2.3</td><td>55</td></tr><tr><td>1.6</td><td>50</td></tr><tr><td>0.6</td><td>45</td></tr><tr><td>4.3</td><td>40</td></tr><tr><td>2.1</td><td>35</td></tr><tr><td>2.5</td><td>30</td></tr><tr><td>1.4</td><td>25</td></tr><tr><td>2.0</td><td>20</td></tr></table> Frequency of Values <table><tr><th>Value</th><th>Count</th></tr><tr><td>9.9</td><td>1500</td></tr></table>	Category	Count	Row Count	1600	Null Count	0	Distinct Count	26	Unique Count	0	Duplicate Count	26	Value	Count	0.5	325	2.8	60	2.3	55	1.6	50	0.6	45	4.3	40	2.1	35	2.5	30	1.4	25	2.0	20	Value	Count	9.9	1500
Category	Count																																							
Row Count	1600																																							
Null Count	0																																							
Distinct Count	26																																							
Unique Count	0																																							
Duplicate Count	26																																							
Value	Count																																							
0.5	325																																							
2.8	60																																							
2.3	55																																							
1.6	50																																							
0.6	45																																							
4.3	40																																							
2.1	35																																							
2.5	30																																							
1.4	25																																							
2.0	20																																							
Value	Count																																							
9.9	1500																																							
Dual_sim	Depois de elaborada a análise geral à coluna «dual_sim», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 2 valores distintos e esses 2 valores são duplicados. Através da análise da frequência de valor, percebe-se que a frequência dos valores 0 e 1 está balanceada. Através da análise do padrão de frequência, percebe-se que todos os valores são constituídos apenas por um dígito.	Simple Statistics <table><tr><th>Category</th><th>Count</th></tr><tr><td>Row Count</td><td>1600</td></tr><tr><td>Null Count</td><td>0</td></tr><tr><td>Distinct Count</td><td>2</td></tr><tr><td>Unique Count</td><td>0</td></tr><tr><td>Duplicate Count</td><td>2</td></tr></table> Frequency of Values <table><tr><th>Value</th><th>Count</th></tr><tr><td>1</td><td>800</td></tr><tr><td>0</td><td>800</td></tr></table> Frequency of Values <table><tr><th>Value</th><th>Count</th></tr><tr><td>9</td><td>1500</td></tr></table>	Category	Count	Row Count	1600	Null Count	0	Distinct Count	2	Unique Count	0	Duplicate Count	2	Value	Count	1	800	0	800	Value	Count	9	1500																
Category	Count																																							
Row Count	1600																																							
Null Count	0																																							
Distinct Count	2																																							
Unique Count	0																																							
Duplicate Count	2																																							
Value	Count																																							
1	800																																							
0	800																																							
Value	Count																																							
9	1500																																							



fc	Depois de elaborada a análise geral à coluna «fc», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 19 valores distintos em que esses 19 valores são duplicados. Através da análise da frequência de valor, percebe-se que o número de mega pixels da camara frontal mais frequente é 0, seguido de 1. Através da análise do padrão de frequência, percebe-se que a maioria do número de mega pixels das camaras frontais são constituídas por 1 dígito e uma menor parte por 2 dígitos.	 The first chart, 'Simple Statistics', shows the distribution of counts for the 'fc' column: Row Count (1600), Null Count (0), Distinct Count (19), Unique Count (0), and Duplicate Count (19). The second chart, 'Value vs Count', is a horizontal bar chart showing the frequency of values from 0 to 8, with 0 being the most frequent. The third chart, 'Value vs Count', is a horizontal bar chart showing the frequency of values 9 and 99, with 9 being the most frequent.
Four_g	Depois de elaborada a análise geral à coluna «four_g», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 2 valores distintos e esses 2 valores são duplicados. Através da análise da frequência de valor, percebe-se que a frequência dos valores 0 e 1 está balanceada. Através da análise do padrão de frequência, percebe-se que todos os valores são constituídos apenas por um dígito.	 The first chart, 'Simple Statistics', shows the distribution of counts for the 'four_g' column: Row Count (1600), Null Count (0), Distinct Count (2), Unique Count (0), and Duplicate Count (2). The second chart, 'Value vs Count', is a horizontal bar chart showing the frequency of values 0 and 1, with 1 being the most frequent. The third chart, 'Value vs Count', is a horizontal bar chart showing the frequency of value 9, which is the most frequent.







Int_memory	Depois de elaborada a análise geral à coluna «int_memory», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 63 valores distintos em que esses 63 valores são duplicados. Através da análise da frequência de valor, percebe-se que a memória interna mais frequente é a de 27, seguido da 2. Através da análise do padrão de frequência, percebe-se que a maioria das memórias internas são constituídas por 2 dígitos e uma menor parte por 1 dígito.	 The first chart, 'Simple Statistics', shows the Row Count (1600), Null Count (0), Distinct Count (63), Unique Count (0), and Duplicate Count (63). The second chart, 'Frequency of Value', shows the count for each value, with 27 having the highest count (around 425) and 2 having the second highest (around 400). The third chart, 'Pattern of Frequency', shows the count for each value, with 99 having the highest count (around 1350) and 9 having the second highest (around 250).
m_dep	Depois de elaborada a análise geral à coluna «m_dep», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 10 valores distintos em que esses 10 valores são duplicados. Através da análise da frequência de valor, percebe-se que a espessura do telemóvel mais frequente é a 0.1, seguido da 0.8. Através da análise do padrão de frequência, percebe-se os valores das a espessura do telemóvel são todos constituídos por um número decimal.	 The first chart, 'Simple Statistics', shows the Row Count (1600), Null Count (0), Distinct Count (10), Unique Count (0), and Duplicate Count (10). The second chart, 'Frequency of Value', shows the count for each value, with 0.1 having the highest count (around 250) and 0.8 having the second highest (around 200). The third chart, 'Pattern of Frequency', shows the count for each value, with 9.9 having the highest count (around 1500) and 9.8 having the second highest (around 1000).

mobile_wt	Depois de elaborada a análise geral à coluna «mobile_wt», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 121 valores distintos em que esses 121 valores são duplicados. Através da análise da frequência de valor, percebe-se que o peso do telemóvel mais frequente é o 101, seguido de 199. Através da análise do padrão de frequência, percebe-se que a maioria dos pesos dos telemóveis são constituídos por 3 dígitos e uma menor parte por 2 dígitos.	  
n_cores	Depois de elaborada a análise geral à coluna «n_cores», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 8 valores distintos em que esses 8 valores são duplicados. Através da análise da frequência de valor, percebe-se que o número de cores mais frequente é 4, seguido de 2. Através da análise do padrão de frequência, percebe-se que os números de cores são todos constituídos por 1 dígito.	  

pc	Depois de elaborada a análise geral à coluna «pc», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 976 valores distintos dos quais 536 são únicos e 440 são duplicados. Através da análise da frequência de valor, percebe-se que o número de mega pixels da câmara principal mais frequente é 7, seguido de 10. Através da análise do padrão de frequência, percebe-se que o número de mega pixels das câmaras principais é constituída por 2 dígitos e por 1 dígito.	 The first chart, 'Simple Statistics', shows the distribution of the 'pc' column: Row Count (1600), Null Count (0), Distinct Count (976), Unique Count (536), and Duplicate Count (440). The second chart, 'Value Frequency', shows the frequency of values for 'pc', with the most frequent being 7 (count ~95) and 10 (count ~90). The third chart, 'Value Pattern', shows the frequency of values for 'pc', with the most frequent being 99 (count ~800) and 9 (count ~750).
Px_height	Depois de elaborada a análise geral à coluna «px_height», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 1010 valores distintos dos quais 607 são únicos e 403 são duplicados. Através da análise da frequência de valor, percebe-se que o número de pixels verticais que o ecrã do telemóvel tem mais frequente é 275, seguido d2 347. Através da análise do padrão de frequência, percebe-se que a maioria do número de pixels verticais que o ecrã do telemóvel tem é constituído por 3 dígitos e uma menor parte por 4 dígitos, ainda menor por 2 dígitos e menor ainda por 1 dígito.	 The first chart, 'Simple Statistics', shows the distribution of the 'Px_height' column: Row Count (1600), Null Count (0), Distinct Count (1010), Unique Count (607), and Duplicate Count (403). The second chart, 'Value Frequency', shows the frequency of values for 'Px_height', with the most frequent being 275 (count ~800) and 347 (count ~750). The third chart, 'Value Pattern', shows the frequency of values for 'Px_height', with the most frequent being 999 (count ~1000) and 9999 (count ~350).

Px_width	Depois de elaborada a análise geral à coluna «px_width», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 992 valores distintos dos quais 567 são únicos e 425 são duplicados. Através da análise da frequência de valor, percebe-se que o número de pixels horizontais que o ecrã do telemóvel tem mais frequente é 874, seguido de 1988. Através da análise do padrão de frequência, percebe-se que a maioria do número de pixels horizontais que o ecrã do telemóvel tem é constituído por 4 dígitos e uma menor parte por 3 dígitos.	 Simple Statistics <table><tr><th>Category</th><th>Count</th></tr><tr><td>Row Count</td><td>1600</td></tr><tr><td>Null Count</td><td>0</td></tr><tr><td>Distinct Count</td><td>992</td></tr><tr><td>Unique Count</td><td>567</td></tr><tr><td>Duplicate Count</td><td>425</td></tr></table>  Frequency distribution <table><tr><th>Value</th><th>Count</th></tr><tr><td>874</td><td>1600</td></tr><tr><td>1988</td><td>1600</td></tr><tr><td>1429</td><td>1600</td></tr><tr><td>519</td><td>1600</td></tr><tr><td>1383</td><td>1600</td></tr><tr><td>1463</td><td>1600</td></tr><tr><td>1247</td><td>1600</td></tr><tr><td>724</td><td>1600</td></tr><tr><td>679</td><td>1600</td></tr><tr><td>507</td><td>1600</td></tr></table>  Pattern distribution <table><tr><th>Value</th><th>Count</th></tr><tr><td>9999</td><td>1600</td></tr><tr><td>999</td><td>1600</td></tr></table>	Category	Count	Row Count	1600	Null Count	0	Distinct Count	992	Unique Count	567	Duplicate Count	425	Value	Count	874	1600	1988	1600	1429	1600	519	1600	1383	1600	1463	1600	1247	1600	724	1600	679	1600	507	1600	Value	Count	9999	1600	999	1600
Category	Count																																									
Row Count	1600																																									
Null Count	0																																									
Distinct Count	992																																									
Unique Count	567																																									
Duplicate Count	425																																									
Value	Count																																									
874	1600																																									
1988	1600																																									
1429	1600																																									
519	1600																																									
1383	1600																																									
1463	1600																																									
1247	1600																																									
724	1600																																									
679	1600																																									
507	1600																																									
Value	Count																																									
9999	1600																																									
999	1600																																									
ram	Depois de elaborada a análise geral à coluna «ram», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 1316 valores distintos dos quais 1065 são únicos e 251 são duplicados. Através da análise da frequência de valor, percebe-se que a capacidade de ram mais frequente é a 2227, seguido da 3142. Através da análise do padrão de frequência, percebe-se que a maioria das capacidades da ram são constituídas por 4 dígitos e uma menor parte por 3 dígitos.	 Simple Statistics <table><tr><th>Category</th><th>Count</th></tr><tr><td>Row Count</td><td>1600</td></tr><tr><td>Null Count</td><td>0</td></tr><tr><td>Distinct Count</td><td>1316</td></tr><tr><td>Unique Count</td><td>1065</td></tr><tr><td>Duplicate Count</td><td>251</td></tr></table>  Frequency distribution <table><tr><th>Value</th><th>Count</th></tr><tr><td>2227</td><td>1600</td></tr><tr><td>3142</td><td>1600</td></tr><tr><td>394</td><td>1600</td></tr><tr><td>1122</td><td>1600</td></tr><tr><td>995</td><td>1600</td></tr><tr><td>841</td><td>1600</td></tr><tr><td>509</td><td>1600</td></tr><tr><td>1229</td><td>1600</td></tr><tr><td>606</td><td>1600</td></tr><tr><td>1214</td><td>1600</td></tr></table>  Pattern distribution <table><tr><th>Value</th><th>Count</th></tr><tr><td>9999</td><td>1600</td></tr><tr><td>999</td><td>1600</td></tr></table>	Category	Count	Row Count	1600	Null Count	0	Distinct Count	1316	Unique Count	1065	Duplicate Count	251	Value	Count	2227	1600	3142	1600	394	1600	1122	1600	995	1600	841	1600	509	1600	1229	1600	606	1600	1214	1600	Value	Count	9999	1600	999	1600
Category	Count																																									
Row Count	1600																																									
Null Count	0																																									
Distinct Count	1316																																									
Unique Count	1065																																									
Duplicate Count	251																																									
Value	Count																																									
2227	1600																																									
3142	1600																																									
394	1600																																									
1122	1600																																									
995	1600																																									
841	1600																																									
509	1600																																									
1229	1600																																									
606	1600																																									
1214	1600																																									
Value	Count																																									
9999	1600																																									
999	1600																																									

Sc_h	Depois de elaborada a análise geral à coluna «sc_h», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 15 valores distintos em que esses 15 valores são duplicados. Através da análise da frequência de valor, percebe-se que a altura do ecrã do telemóvel mais frequente é 17, seguido de 12. Através da análise do padrão de frequência, percebe-se que a maioria das alturas dos ecrãs dos telemóveis são constituídas por 2 dígitos e uma menor parte por 1 dígito.	 The first chart, 'Simple Statistics', shows the distribution of data for 'sc_h'. The y-axis is 'Count' (0 to 1500) and the x-axis is 'Simple Statistics' with categories: Row Count (1600), Null Count (0), Distinct Count (15), Unique Count (0), and Duplicate Count (15). The second chart, 'Frequency of Value', shows the frequency of screen heights. The y-axis is 'Value' (9 to 17) and the x-axis is 'Count' (0 to 150). The third chart, 'Frequency of Pattern', shows the frequency of screen height patterns. The y-axis is 'Value' (9 to 99) and the x-axis is 'Count' (0 to 1100).
Sc_w	Depois de elaborada a análise geral à coluna «sc_w», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 19 valores distintos em que esses 19 valores são duplicados. Através da análise da frequência de valor, percebe-se que a largura do ecrã do telemóvel mais frequente é 1, seguido de 3. Através da análise do padrão de frequência, percebe-se que a maioria das larguras dos ecrãs dos telemóveis são constituídas por 1 dígito e uma menor parte por 2 dígitos.	 The first chart, 'Simple Statistics', shows the distribution of data for 'sc_w'. The y-axis is 'Count' (0 to 1500) and the x-axis is 'Simple Statistics' with categories: Row Count (1600), Null Count (0), Distinct Count (19), Unique Count (0), and Duplicate Count (19). The second chart, 'Frequency of Value', shows the frequency of screen widths. The y-axis is 'Value' (1 to 10) and the x-axis is 'Count' (0 to 170). The third chart, 'Frequency of Pattern', shows the frequency of screen width patterns. The y-axis is 'Value' (9 to 99) and the x-axis is 'Count' (0 to 1300).

Talk_time	Depois de elaborada a análise geral à coluna «talk_time», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 19 valores distintos em que esses 19 valores são duplicados. Através da análise da frequência de valor, percebe-se que o tempo máximo que a bateria de um telemóvel pode durar durante uma chamada telefônica mais frequente é 16, seguido de 7. Através da análise do padrão de frequência, percebe-se que a maioria dos tempos máximos que as baterias dos telemóveis podem durar durante as chamadas telefônicas são constituídas por 2 dígitos e uma menor parte por 1 dígito.	 Simple Statistics <table><tr><th>Statistic</th><th>Count</th></tr><tr><td>Row Count</td><td>1600</td></tr><tr><td>Null Count</td><td>0</td></tr><tr><td>Distinct Count</td><td>19</td></tr><tr><td>Unique Count</td><td>0</td></tr><tr><td>Duplicate Count</td><td>19</td></tr></table>  Frequency of values <table><tr><th>Value</th><th>Count</th></tr><tr><td>16</td><td>95</td></tr><tr><td>7</td><td>90</td></tr><tr><td>4</td><td>85</td></tr><tr><td>19</td><td>80</td></tr><tr><td>6</td><td>75</td></tr><tr><td>15</td><td>70</td></tr><tr><td>2</td><td>65</td></tr><tr><td>10</td><td>60</td></tr><tr><td>17</td><td>55</td></tr><tr><td>13</td><td>50</td></tr></table>  Pattern of frequency <table><tr><th>Value</th><th>Count</th></tr><tr><td>99</td><td>900</td></tr><tr><td>9</td><td>700</td></tr></table>	Statistic	Count	Row Count	1600	Null Count	0	Distinct Count	19	Unique Count	0	Duplicate Count	19	Value	Count	16	95	7	90	4	85	19	80	6	75	15	70	2	65	10	60	17	55	13	50	Value	Count	99	900	9	700
Statistic	Count																																									
Row Count	1600																																									
Null Count	0																																									
Distinct Count	19																																									
Unique Count	0																																									
Duplicate Count	19																																									
Value	Count																																									
16	95																																									
7	90																																									
4	85																																									
19	80																																									
6	75																																									
15	70																																									
2	65																																									
10	60																																									
17	55																																									
13	50																																									
Value	Count																																									
99	900																																									
9	700																																									
Three_g	Depois de elaborada a análise geral à coluna «three_g», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 2 valores distintos e esses 2 valores são duplicados. Através da análise da frequência de valor, percebe-se que a frequência dos valores 0 e 1 está balanceada. Através da análise do padrão de frequência, percebe-se que todos os valores são constituídos apenas por um dígito.	 Simple Statistics <table><tr><th>Statistic</th><th>Count</th></tr><tr><td>Row Count</td><td>1600</td></tr><tr><td>Null Count</td><td>0</td></tr><tr><td>Distinct Count</td><td>2</td></tr><tr><td>Unique Count</td><td>0</td></tr><tr><td>Duplicate Count</td><td>2</td></tr></table>  Frequency of values <table><tr><th>Value</th><th>Count</th></tr><tr><td>1</td><td>1200</td></tr><tr><td>0</td><td>400</td></tr></table>  Pattern of frequency <table><tr><th>Value</th><th>Count</th></tr><tr><td>9</td><td>1500</td></tr></table>	Statistic	Count	Row Count	1600	Null Count	0	Distinct Count	2	Unique Count	0	Duplicate Count	2	Value	Count	1	1200	0	400	Value	Count	9	1500																		
Statistic	Count																																									
Row Count	1600																																									
Null Count	0																																									
Distinct Count	2																																									
Unique Count	0																																									
Duplicate Count	2																																									
Value	Count																																									
1	1200																																									
0	400																																									
Value	Count																																									
9	1500																																									

Touch_screen	Depois de elaborada a análise geral à coluna «touch_screen», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 2 valores distintos e esses 2 valores são duplicados. Através da análise da frequência de valor, percebe-se que a frequência dos valores 0 e 1 está balanceada. Através da análise do padrão de frequência, percebe-se que todos os valores são constituídos apenas por um dígito.	The first chart, 'Simple Statistics', is a vertical bar chart showing counts for Row Count (1600), Null Count (0), Distinct Count (2), Unique Count (0), and Duplicate Count (2). The second chart, 'Frequency', is a horizontal bar chart showing counts for values 0 and 1, both around 800. The third chart, 'Pattern', is a horizontal bar chart showing counts for values 0 and 1, both around 1500.
wifi	Depois de elaborada a análise geral à coluna «wifi», concluímos que esta possui um total de 1600 linhas, não tem linhas nulas, possui 2 valores distintos e esses 2 valores são duplicados. Através da análise da frequência de valor, percebe-se que a frequência dos valores 0 e 1 está balanceada. Através da análise do padrão de frequência, percebe-se que todos os valores são constituídos apenas por um dígito.	The first chart, 'Simple Statistics', is a vertical bar chart showing counts for Row Count (1600), Null Count (0), Distinct Count (2), Unique Count (0), and Duplicate Count (2). The second chart, 'Frequency', is a horizontal bar chart showing counts for values 0 and 1, both around 800. The third chart, 'Pattern', is a horizontal bar chart showing counts for values 0 and 1, both around 1500.




Tabela 5- Qualidade de Dados

2.4.1. RESULTADOS DA AVALIAÇÃO

Após analisarmos a qualidade dos dados do dataset com recurso ao *talend*, chegamos à conclusão de que não existem problemas de qualidade. Não foram necessárias quaisquer medidas de correção, por não se verificarem valores nulos ou vazios.

Em relação aos *outliers*, estes representam uma minoria insignificante de dados. Optamos então pela sua remoção porque não têm um impacto significativo na nossa análise.

3. DATA PREPARATION

3.1. SELEÇÃO DOS DADOS

Após analisar cuidadosamente a qualidade e a relevância dos dados do conjunto de dados, concluímos que não há necessidade de alterar os atributos selecionados. Todos os atributos listados - Battery_power, Blue, Clock_speed, Dual_sim, fc, For_g, Int_memory, M_dep, Mobile_wt, N_cores, Px_height, Px_width, Ram, Sc_h, Sc_w, Talk_time, Three_g, Touch_screen, wifi e Price_range - são fundamentais para a análise de preços de telemóveis.

Esses atributos são essenciais para a estimativa de preços de telemóveis, uma vez que cada um deles oferece informações valiosas sobre as características dos dispositivos. Por exemplo, a capacidade da bateria (Battery_power), a memória RAM, a resolução da tela (Sc_h e Sc_w), entre outros, são fatores cruciais que influenciam diretamente o preço de um telemóvel no mercado.

Portanto, todos os atributos são relevantes e representativos para atender aos critérios estabelecidos para a análise de preços. Eles são indispensáveis para alcançar o objetivo principal do negócio, que é estimar os preços dos telemóveis com base em suas características, permitindo ao Bob ajustar estrategicamente os preços para maximizar os lucros e melhorar a competitividade no mercado de telemóveis.

3.2. LIMPEZA DOS DADOS

A limpeza dos dados consiste em analisar todos os dados que continham incoerências.

Com base na análise da qualidade dos dados em cada coluna, incluindo uma análise geral, uma investigação da frequência dos valores e uma análise do padrão de frequência, realizada no ponto [Verificação da Qualidade dos dados](#), podemos concluir que não são necessárias medidas corretivas.

Após avaliarmos detalhadamente a qualidade dos dados em todas as colunas, constatamos que não há nenhuma linha nula ou qualquer campo em branco. A análise geral revelou uma consistência satisfatória nos dados, enquanto a frequência dos valores e os padrões identificados mantêm-se dentro dos limites esperados, sem desvios relevantes que possam comprometer a integridade ou precisão das informações.

Essa conclusão aponta para a solidez e confiabilidade dos dados apresentados, sugerindo que não há a necessidade imediata de implementar medidas corretivas.

O grupo propôs-se a realizar uma limpeza dos dados no que diz respeito aos *outliers* existentes nas colunas *fc* e *px_height*.

Na coluna de “*fc*” removemos todos os valores acima de 16 e na coluna “*px_height*” removemos todos os valores acima de 1949.




Figura 9- Sem outliers

Ao analisarmos o conjunto de dados, constatamos que este se encontra balanceado em relação à variável *target*. Esta distribuição equitativa é crucial, uma vez que em situações onde existe um desequilíbrio entre as classes, as técnicas de *machine learning* têm tendência a atribuir mais peso ou importância às classes mais frequentes. Com um conjunto de dados equilibrado, evitamos que os modelos de *machine learning* sejam influenciados por uma predominância de uma classe sobre as outras, garantindo que todas as classes tenham representatividade suficiente para que o algoritmo aprenda de forma mais precisa e justa, sem favorecer uma classe em detrimento das outras.

3.3. CONSTRUÇÃO DOS DADOS

Esta parte garante que o conjunto de dados esteja pronto para ser utilizado na modelagem. Desta forma foi-nos proposto a criação de 4 cenários.

	todas	Correlação $\geq x$
c/outliers	C1	C2
s/outliers	C3	C4

Tabela 6- Cenários

Cenários	Conclusão
Cenário 1	Conjuntos de dados que inclui todas as variáveis com <i>outliers</i> . Oferece uma visão completa dos dados, é útil para entender a amplitude total dos dados, mas os resultados são menos confiáveis devido à presença de valores extremos. Estes valores podem afetar significativamente a média e o desvio padrão, influenciando nas análises estatísticas.
Cenário 2	Conjuntos de dados que contém <i>outliers</i> mas apenas inclui aquelas variáveis, cuja a correlação com a target está acima do valor x, ou seja, iremos remover as colunas que não cumprem esse requisito. Ajuda a destacar as relações mais fortes entre as variáveis, mas com o <i>outliers</i> afeta a precisão. Como os <i>outliers</i> fazem parte das que tem correlação, não mudou nada. O valor do target que definimos foi 0.15 .
Cenário 3	Conjunto de dados onde não há <i>outliers</i> em nenhuma das variáveis, ou seja, iremos apenas remover as linhas que contém <i>outliers</i> . É uma análise mais confiável e estável e mostra maior precisão, mas não tanta amplitude.
Cenário 4	Conjuntos de dados sem <i>outliers</i> e só inclui aquelas variáveis acima do valor do target. Oferece abordagem mais focada e mais precisa.

Tabela 7 – Conclusão dos cenários

Após a elaboração dos cenários, concluímos que cada um demonstra formas diferentes de análise do *dataset* consoante o que se pretende.

3.4. INTEGRAÇÃO DOS DADOS

Uma vez que foram realizadas análises e tratamento de dados apenas para o *dataset train*, não houve necessidade de proceder à integração dos dados.

3.5. FORMATAÇÃO DOS DADOS

Cenário	Variáveis	Número de variáveis	Número de linhas
Cenário 1	battery_power, blue, clock_speed, dual_sim, fc, four_g, int_memory, m_dep, mobile_wt, n_cores, pc, px_height, px_width, ram, sc_h, sc_w, talk_time, three_g, touch_screen, wifi, price_range	21	1600
Cenário 2	battery_power,price_range,px_height,px_width,ram	5	1600
Cenário 3	battery_power, blue, clock_speed, dual_sim, fc,four_g, int_memory, m_dep, mobile_wt, n_cores, pc, px_height, px_width, ram, sc_h, sc_w, talk_time, three_g, touch_screen, wifi, price_range	21	1586
Cenário 4	battery_power,price_range,px_height,px_width,ram	5	1586

Tabela 8- Formatação dos dados

4. MODELING

4.1. SELECIONAR TÉCNICAS DE MODELAÇÃO

Nesta fase foram selecionadas as várias técnicas de modelação a aplicar quatro cenários criados na fase anterior. As técnicas escolhidas são as seguintes:

Decison Tree - técnica de modelagem preditiva que permite criar estruturas de decisão baseadas em conjuntos de regras condicionais. Uma árvore de decisão é constituída por nós, que são os atributos, por folhas, que são classes ou objetos e por último, tem ramos, que são os valores dos atributos.

RandomForest - é um método de aprendizagem conjunta para classificação e regressão que utiliza múltiplas arvores de decisão para fazer previsões.

Naive Bayes - é um algoritmo que gera uma tabela de probabilidades a partir de uma técnica de classificação de dados. Ele se baseia no Teorema de Bayes, fazendo uma suposição "ingênua" de independência entre as características. Apesar dessa simplificação, o Naive Bayes é eficaz e rápido, sendo útil em grandes conjuntos de dados, onde a simplicidade e a velocidade de treinamento são prioritárias

Redes neuronais - são sistemas de computação com nós interconectados que funcionam de forma muito semelhante aos neurónios que fazem parte do cérebro humano. Ao utilizarmos em algoritmos, conseguimos reconhecer padrões escondidos e correlações em dados não processados.

SVM (support-vector machine) - um algoritmo de aprendizado de máquina utilizado para classificação e regressão. Sua principal característica é a capacidade de encontrar um Hiper plano de decisão ótimo que separa os dados de diferentes classes de maneira eficiente.

4.2. GERAR MODELOS DE TESTE

Nesta fase, a equipa definiu diversos cenários e mecanismos para testar a qualidade do modelo. Cada um dos cenários criados são compostos por uma combinação de variáveis, fornecidas pelo dataset, técnicas usadas e métodos de teste e validação. Na tabela seguinte, encontra-se os cenários criados pela equipa.

Cenário	Atributos Seleccionados	Técnicas a usar	Método de Teste e Validação
1	Todas as variáveis	Todas	Cross- Validation
2	Variáveis com correlação > 0.5	Todas	Cross- Validation
3	Sem outliers	Todas	Cross- Validation
4	Sem outliers e ci variáveis com correlação > 0.5	Todas	Cross- Validation

Tabela 9- Gerar modelos de Teste

4.3. CONSTRUIR MODELO

Após a definição dos cenários de teste e a escolha das técnicas de modelação, procede-se à configuração das ferramentas necessárias. No que diz respeito à ferramenta de modelagem, optou-se pelo RapidMiner, onde geralmente existe uma variedade de parâmetros passíveis de ajuste. Nas figuras seguintes, apresentam-se os diversos parâmetros associados a cada um dos modelos.

Em [anexo](#) encontra-se mais detalhes em relação à construção de cada modelo.


RANDOM FOREST

The screenshot shows the 'Parameters' window for the 'Random Forest' model. The parameters are as follows:

- number of trees**: 100
- criterion**: gain_ratio
- maximal depth**: 10
- apply pruning**: unchecked
- apply prepruning**: unchecked
- guess subset ratio**: checked
- voting strategy**: confidence vote

Figura 10- Parâmetros associados a Random Forest

DECISION TREE




The screenshot shows a 'Parameters' window for a 'Decision Tree' model. The parameters are as follows:

Parameter	Value
criterion	gain_ratio
maximal depth	10
apply pruning	☒
confidence	0.1
apply prepruning	☒
minimal gain	0.01
minimal leaf size	2

Figura 11- Parâmetros associados a Decision Tree

Em [anexo](#) encontra-se os modelos obtidos nas árvores de decisão. Ao analisar cada uma das árvores de decisão, podemos concluir que a variável "ram" é aquela que apresenta a maior variação no preço em todos os cenários, uma vez que é a primeira na árvore.

REDES NEURONAIS



The screenshot shows a 'Parameters' window for a 'Neural Net' model. The parameters are as follows:

Parameter	Value
hidden layers	Edit List (0)...
training cycles	200
learning rate	0.01
momentum	0.9
decay	☐
shuffle	☒
normalize	☒
error epsilon	1.0E-4
use local random seed	☐

Figura 12 -Parâmetros associados às redes neurais

NAIVE BAYES

Parameters

Naive Bayes

☒ *laplace correction*

Figura 13-Parâmetros associados a Naive Baves

SVM

Parameters

SVM (Support Vector Machine)

kernel type

polynomial

kernel degree

2.0

kernel cache

200

C

0.0

convergence epsilon

0.001

max iterations

100000

☒ scale

L pos

1.0

L neg

1.0

epsilon

0.0

epsilon plus

0.0

epsilon minus

0.0

☐ balance cost

Figura 14- Parâmetros associados a SVM

4.4. AVALIAR MODELO

O nosso problema é de classificação com a variável target 'price range'. Inicialmente tínhamos quatro valores distintos representando diferentes faixas de preço. No entanto, para facilitar a avaliação do desempenho do nosso modelo, optamos por transformar essa variável, consolidando os valores em duas categorias distintas. Essas reagrupação nos permite aplicar métricas de avaliação adequadas para problemas binários, que consideram apenas dois resultados possíveis: positivo e negativo. Dessa forma, conseguimos utilizar métricas como precisão, recall, F1-score, accuracy, kappa e precision, focando na distinção entre as classes reunidas após a transformação.

- **Accuracy** (acurácia): Essa métrica é amplamente utilizada para avaliar o desempenho global de um modelo de *machine learning*, proporcionando uma medida geral da precisão das previsões em comparação com o conjunto total de dados. Expressa-se como uma percentagem, onde uma acurácia mais elevada, indica um melhor desempenho do modelo.
- **Kappa**: métrica estatística que mede a concordância entre as previsões do modelo e as observações reais. O coeficiente kappa varia de -1 a 1, onde 1 indica concordância perfeita entre as previsões do modelo e as etiquetas verdadeiras, -1 indica discordância completa, e 0 sugere que o modelo não supera o acaso. Portanto, o kappa é uma métrica valiosa, especialmente quando se lida com conjuntos de dados desequilibrados.
- **AUC**: Mede a área sob a Curva ROC, que representa a capacidade de um modelo de classificação binária distinguir entre classes positivas e negativas. Um valor AUC mais alto indica melhor desempenho.
- **Precision** (precisão): métrica que mede a proporção de previsões positivas que estão realmente corretas. É relevante quando o foco está em evitar falsos positivos.
- **Recall**: Sensibilidade ou taxa de verdadeiros positivos, é uma métrica de avaliação em modelos de classificação que mede a capacidade do modelo de identificar corretamente todas as instâncias positivas no conjunto de dados.
- **F1 Score**: métrica que combina precisão (precision) e recall em uma única pontuação, proporcionando uma medida geral do desempenho de um modelo de classificação. Essa métrica é particularmente útil quando há desequilíbrio nas classes do conjunto de dados.

Realizamos então um estudo para cada cenário e interpretar os resultados obtidos em cada modelo de acordo com a nossa experiência, conhecimento e critérios definidos.

Apesar da existência de uma grande quantidade de métricas a serem avaliadas, o grupo focou-se essencialmente no F1 score, também conhecida como F-measure, é uma métrica comum na avaliação de modelos de classificação. Ela combina as métricas de precision e recall, fornecendo uma medida mais equilibrada do desempenho do modelo.

A precisão é a proporção de instâncias positivas classificadas corretamente em relação ao total de instâncias positivas previstas pelo modelo. O recall, por outro lado, é a proporção de instâncias positivas corretamente identificadas em relação ao total de instâncias positivas reais.

O F1 Score é calculado pela fórmula:

$$\text{F1 Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Essa métrica é especialmente útil quando há um desequilíbrio entre as classes, pois leva em consideração tanto os falsos positivos quanto os falsos negativos. Um valor de F1 Score mais alto indica um modelo mais equilibrado em termos de precisão e recall.

Ou seja, o F1 Score é uma métrica crucial para determinar a capacidade do sistema em prever corretamente uma melhor estimativa do preço de um telemóvel com base nas suas características. Ao avaliar o desempenho do modelo com base nessa métrica, o Bob poderá ajustar os preços dos seus telemóveis de maneira a maximizar os seus lucros em 5%.

A importância do F1 Score neste contexto reside no fato de que ele oferece uma visão equilibrada entre a precisão e o recall do modelo. Isso significa que, ao considerar tanto os falsos positivos quanto os falsos negativos, o Bob pode ter uma medida mais abrangente da eficácia do seu sistema na estimativa de preços.

Ao utilizar o F1 Score como métrica principal, o Bob estará melhor posicionado para alcançar o objetivo de negócio de maximizar os lucros em 5%, melhorando assim a competitividade no mercado de telemóveis. Esta escolha reflete a relevância direta dessa métrica para o desenvolvimento correto do trabalho, contribuindo de maneira significativa para atingir o objetivo de negócio estabelecido.

CENÁRIO 1

Métricas	Técnicas				
	Random forest	Decision Tree	Redes neuronais	Naive bayes	SVM
accuracy	92.62% +/- 2.62%	93.81% +/- 2.54%	97.81% +/- 1.36%	93.62% +/- 1.88%	93.25% +/- 2.18%
kappa	0.884 +/- 0.052	0.876 +/- 0.051	0.956 +/- 0.027	0.872 +/- 0.038	0.865 +/- 0.044
AUC	0.984 +/- 0.005	0.930 +/- 0.026	0.998 +/- 0.001	0.986 +/- 0.006	0.985 +/- 0.006
precision	91.15% +/- 3.78%	93.90% +/- 2.66%	97.89% +/- 1.83%	93.66% +/- 2.30%	92.99% +/- 3.05%
recall	93.62% +/- 2.85%	93.75% +/- 3.28%	97.75% +/- 1.15%	93.62% +/- 2.16%	93.62% +/- 1.50%
F1 score	92.32% +/- 2.48%	93.80% +/- 2.56%	97.82% +/- 1.34%	93.63% +/- 1.88%	93.29% +/- 2.11%

Tabela 10- Técnicas para Cenário 1

De acordo com as métricas escolhidas, as redes neuronais são a técnica de aprendizado de máquina que apresenta o melhor desempenho para o cenário em questão. Podemos observar que as redes neuronais se destacaram com valores mais altos e as outras técnicas mostraram valores mais parecidos entre elas como a acurácia na faixa 92% a 93%, o recall nos 93%, a precisão esta entre 91% e 93% e a score o mesmo. A métrica kappa mostra que todas as técnicas mantêm uma boa concordância entre previsões e observações reais. Os valores variam de 0.872 a 0.956, indicando que os modelos têm a capacidade de superar acertos ao acaso. Na AUC, que mede a capacidade de distinguir entre classes positivas e negativas, todos os modelos apresentaram um desempenho notável, com valores variando de 0.930 a 0.998. Isso sugere que as técnicas são eficazes na separação das classes, mesmo que haja alguma variação nos resultados.

Os resultados gerais indicam que todas as técnicas são competentes, e a escolha entre elas pode depender de considerações específicas, como interoperabilidade do modelo, recursos computacionais disponíveis ou requisitos práticos da aplicação.

Melhor modelo: Redes neurais

CENÁRIO 2

Métricas	Técnicas				
	Random Forest	Decision Tree	Redes neurais	Naive bayes	SVM
accuracy	95.12% +/- 1.81%	93.81% +/- 2.54%	98.44% +/- 1.22%	93.69% +/- 1.85%	56.12% +/- 4.93%
kappa	0.903 +/- 0.036	0.876 +/- 0.051	0.969 +/- 0.024	0.874 +/- 0.037	0.123 +/- 0.099
AUC	0.994 +/- 0.003	0.942 +/- 0.021	0.999 +/- 0.001	0.987 +/- 0.006	0.596 +/- 0.063
precision	94.32% +/- 2.89%	93.90% +/- 2.66%	98.30% +/- 2.20%	93.68% +/- 2.41%	54.08% +/- 3.38%
recall	96.12% +/- 1.50%	93.75% +/- 3.28%	98.62% +/- 0.71%	93.75% +/- 2.43%	81.75% +/- 5.41%
F1 score	95.19% +/- 1.72%	93.80% +/- 2.56%	98.45% +/- 1.20%	93.69% +/- 1.84%	65.07% +/- 3.93%

Tabela 11- Técnicas para Cenário 2

Observamos que as redes neurais alcançam novamente valores mais altos em várias métricas, com uma acurácia de 98,44%. O SVM apresentou um desempenho inferior em comparação com as outras, particularmente na acurácia e AUC, sugerindo dificuldades na realização de previsões precisas e na separação eficaz das classes. As métricas de precision e recall revelam que tanto as Redes Neurais quanto a Random Forest apresentam valores elevados, indicando uma capacidade consistente de realizar previsões corretas positivas e de identificar a maioria das positivas, respetivamente. No entanto, a SVM exibe uma precisão mais baixa, sugerindo uma tendência a classificar incorretamente algumas instâncias como positivas. Resumindo, as redes neurais continuam a destacar-se como a técnica com melhor desempenho.

Melhor modelo: Redes neurais

CENÁRIO 3

Métricas	Técnicas				
	Random Forest	Decision Tree	Redes neuronais	Naive bayes	SVM
accuracy	92.19% +/- 2.53%	92.94% +/- 1.48%	97.79% +/- 1.16%	93.57% +/- 2.45%	93.25% +/- 2.01%
kappa	92.19% +/- 2.53%	0.859 +/- 0.030	0.956 +/- 0.023	0.871 +/- 0.049	0.865 +/- 0.040
AUC	0.985 +/- 0.009	0.928 +/- 0.029	0.999 +/- 0.001	0.986 +/- 0.008	0.985 +/- 0.006
precision	90.80% +/- 2.88%	93.01% +/- 2.21%	97.75% +/- 1.42%	93.75% +/- 3.07%	91.93% +/- 2.95%
recall	93.96% +/- 2.87%	92.95% +/- 2.85%	97.86% +/- 1.68%	93.45% +/- 2.55%	94.96% +/- 2.53%
F1 score	92.33% +/- 2.48%	92.94% +/- 1.51%	97.80% +/- 1.16%	93.58% +/- 2.43%	93.38% +/- 1.95%

Tabela 12- Técnicas para Cenário 3

Ao analisar a tabela de desempenho das diferentes técnicas, as Redes Neurais destacam-se com a maior acurácia, kappa, AUC e precisão, indicando uma capacidade superior de realizar previsões corretas e distinguir entre classes positivas e negativas. Para a acurácia, toda as outras apresentam valores entre 92% a 93%, exceto as Redes Neurais. A métrica kappa, que reflete a concordância ajustada entre previsões e observações reais, reforça a superioridade das Redes, com um valor de 97.79%. A Área sob a Curva ROC (AUC), uma medida crucial da capacidade de distinguir entre classes positivas e negativas, os valores das outras técnicas são quase iguais com 0.985 sem ser a Decision Tree. Em síntese, as Redes Neurais continuam a se destacar como a técnica de aprendizado de máquina mais eficaz neste cenário específico. A sua consistência e desempenho superior em diversas métricas sublinham a sua capacidade excepcional de realizar previsões precisas e distintas entre classes, consolidando as Redes Neurais como a escolha preferencial para este problema.

Melhor modelo: Redes neuronais

CENÁRIO 4

Métricas	Técnicas				
	Random Forest	Decision Tree	Redes neuronais	Naive bayes	SVM
accuracy	95.34% +/- 1.93%	94.33% +/- 1.75%	98.74% +/- 0.73%	93.76% +/- 2.74%	55.54% +/- 3.09%
kappa	0.907 +/- 0.039	0.887 +/- 0.035	0.975 +/- 0.015	0.875 +/- 0.055	0.111 +/- 0.063
AUC	0.994 +/- 0.005	0.948 +/- 0.030	0.999 +/- 0.001	0.986 +/- 0.009	0.584 +/- 0.056
precision	94.57% +/- 2.00%	94.52% +/- 2.66%	98.40% +/- 1.41%	93.93% +/- 3.71%	53.77% +/- 2.11%
recall	96.23% +/- 2.27%	94.22% +/- 2.43%	99.12% +/- 0.61%	93.71% +/- 2.90%	80.62% +/- 5.91%
F1 score	95.38% +/- 1.91%	94.33% +/- 1.73%	98.75% +/- 0.71%	93.78% +/- 2.69%	64.44% +/- 2.82%

Tabela 13- Técnicas para cenário 4

Analisando o último cenário, conseguimos perceber que para além de as redes continuarem a ser a técnica que se destaca, por outro lado temos o SVM que se destaca por ter valores mais baixo comparando com as outras técnicas em praticamente todas as métricas. O Random forest e Decision Tree demonstram um desempenho sólido com uma acurácia de 94% a 95%, no kappa também. No AUC o Random Forest atinge um valor muito próximo da técnica escolhida, sugerindo uma capacidade semelhante na distinção entre classes positivas e negativas. No entanto, na precision e recall as técnicas apresentam valores longe das redes. O score todos mantém valores entre 95 % e 94% exceto o SVM que já indicado anteriormente, é o que regista valores mais baixos. Em todos os cenários as Redes neuronais apresentaram sempre os melhores valores e com este último cenário podemos perceber que a escolha preferencial será essa mesma técnica.

Melhor modelo: Redes neuronais

4.5. SELECIONAR O MELHOR MODELO

Na tabela seguinte, são apresentados os valores de todas as métricas do melhor modelo selecionado anteriormente para cada um dos quatro cenários.

Cenário/Métrica	accuracy	kappa	AUC	precision	recall	F1 score	Técnica
Cenário 1	97.81% +/- 1.36%	0.956 +/- 0.027	0.998 +/- 0.001	97.89% +/- 1.83%	97.75% +/- 1.15%	97.82% +/- 1.34%	Redes neuronais
Cenário 2	98.44% +/- 1.22%	0.969 +/- 0.024	0.999 +/- 0.001	98.30% +/- 2.20%	98.62% +/- 0.71%	98.45% +/- 1.20%	Redes neuronais
Cenário 3	97.79% +/- 1.16%	0.956 +/- 0.023	0.999 +/- 0.001	97.75% +/- 1.42%	97.86% +/- 1.68%	97.80% +/- 1.16%	Redes neuronais
Cenário 4	98.74% +/- 1.91%	0.975 +/- 1.73%	0.999 +/- 0.71%	98.40% +/- 1.41%	99.12% +/- 0.61%	98.75% +/- 0.61%	Redes neuronais

Figura 15- Escolha do Modelo

É evidente que, de maneira geral, todos os modelos exibem resultados bastante semelhantes entre si. Entretanto, ao analisar mais detalhadamente os cenários, destaca-se que o modelo mais propício a auxiliar na consecução dos objetivos é, de facto, as Redes Neuronais, principalmente no contexto do cenário 4.

O cenário 4 destaca-se ao apresentar os valores mais elevados em todas as métricas avaliadas, inclusive no F1-score, revelando um desempenho superior. Esse cenário está relacionado aos conjuntos de dados sem outliers, considerando apenas as variáveis que ultrapassam o valor do target. Os resultados mais elevados nas métricas indicam que as Redes Neuronais, neste contexto específico, conseguem proporcionar um desempenho superior em comparação com as demais técnicas.

Em termos gerais, a F1-score, sendo uma medida que combina precisão e recall, destaca-se como um indicador relevante da acuidade e da precisão do classificador. Nesse sentido, a escolha das Redes Neuronais no cenário 4 é apoiada pelo seu desempenho robusto em todas as métricas, sugerindo uma capacidade consistente de realizar previsões precisas e identificar corretamente as instâncias positivas.

É relevante notar que o F1-score vai ser o fator discriminante na avaliação e o seu valor mais alto no cenário 4 reforça a superioridade deste modelo específico, consolidando-o como a escolha mais promissora para atingir os objetivos delineados. A precisão e foco deste cenário contribuem de maneira significativa para a eficácia do modelo de Redes Neuronais na resolução do problema em questão.

5. EVALUATION

5.1. AVALIAÇÃO DE RESULTADOS

Na fase de Evaluation do CRISP-DM, o objetivo é analisar o desempenho do modelo escolhido, que, no seu caso, é o cenário 4. Esse cenário se destaca por lidar com conjuntos de dados sem outliers, incluindo apenas variáveis acima do valor do target, proporcionando uma abordagem mais focada e precisa. O f1-score obtido foi de 98.75%, indicando um excelente desempenho na classificação.

De acordo com a metodologia CRISP-DM, a Evaluation é crucial para entender como o modelo se comporta após a fase de modelação. Neste contexto, o objetivo é permitir que o Bob faça uma estimativa mais precisa do preço de um telemóvel com base em suas características. O Bob pretende ajustar os preços dos telemóveis para estimar o preço de venda com um erro inferior a 5%.

Os critérios de sucesso de Data Mining, neste caso, estão relacionados à percentagem de acuidade, que representa quão bem o modelo prevê a faixa de preço dos telemóveis com base nas características fornecidas. Com uma alta percentagem de acuidade, como os impressionantes 98.75%, o modelo classifica corretamente a maioria dos telemóveis nas categorias de preço.

Com base no notável desempenho do modelo, que alcançou um f1-score de 98.75%, podemos tirar conclusões positivas em relação ao cumprimento dos objetivos de negócio e critérios de sucesso estabelecidos. A alta acuidade do modelo, superando os 95% desejados, indica uma capacidade excepcional de prever a faixa de preço dos telemóveis com base em suas características.

O cumprimento do objetivo de negócio, que envolve a estimativa do preço de venda com um erro inferior a 5%, é claramente evidenciado pelo desempenho do modelo. Com uma acuidade de 98.75%, o modelo não apenas atendeu a esse critério, mas também superou as expectativas, proporcionando uma margem de segurança considerável de 3.75%.

Portanto, com base nesses resultados, podemos concluir que o modelo selecionado tem a capacidade necessária para atingir os objetivos propostos. A sua precisão excepcional sugere que o Bob pode confiar nas estimativas de preços geradas pelo modelo para ajustar os preços dos telemóveis, alcançando assim uma estimativa com um erro aceitável e cumprindo com sucesso os critérios estabelecidos para o projeto.

5.2. REVISÃO DO PROCESSOS

No decorrer deste projeto, deparamo-nos com desafios significativos que impactaram diretamente a qualidade e eficácia da análise. Uma das principais limitações que merece atenção refere-se à natureza dos dados utilizados. A utilização dos dados pressupõe que eles são reais, provenientes de uma fonte fidedigna e não contêm erros substanciais. A ausência de contextos específicos para cada atributo dificultou a interpretação correta dos dados.

Além disso, a apresentação de todos os dados em formato de código também contribuiu para a complexidade na análise. A falta de descrições claras para os atributos dificultou a compreensão do contexto subjacente, prejudicando a capacidade de explorar completamente as nuances dos dados, e por isso foi necessário realizar uma pesquisa para compreender o significado de cada atributo.

Concluindo a revisão detalhada do processo, observamos que o modelo desenvolvido é satisfatório e alinhado com o objetivo de negócio. Este processo reforça a confiança na solidez e confiabilidade dos modelos para a estimativa de preços de telemóveis, ao mesmo tempo em que destaca áreas para melhorias futuras no tratamento e compreensão dos dados utilizados.

5.3. DETERMINAÇÃO DOS PRÓXIMOS PASSOS

Com base nos resultados da avaliação e da revisão do processo e considerando os modelos obtidos, verificamos que possível otimizar alguns cenários. Essa otimização requer uma análise mais precisa dos dados, utilizando ferramentas mais adequadas para melhorar significativamente a qualidade dos dados. O que poderíamos fazer para melhorar era realizar uma análise ainda mais aprofundada dos cenários investigar e implementar técnicas avançadas de pré-processamento de dados para melhorar a qualidade.

Para futuras iterações, é necessário obter mais informações sobre os dados para tirar conclusões mais robustas, garantindo uma amostragem clara e precisa. Reconhecemos também a importância contínua do refinamento e aprimoramento para garantir o sucesso do projeto em suas futuras fases e iterações.

REFERÊNCIAS

Material suporte às aulas disponibilizado pelo docente na Blackboard

<https://www.kaggle.com/competitions/2324aasetp3/data>

<https://academy.rapidminer.com/>

<https://www.datascience-pm.com/crisp-dm-2/>

ANEXO

MÉDIA + DESVIO PADRÃO

```
#numericos
selected_columns = d[["battery_power", "clock_speed", "fc", "int_memory", "m_dep", "mobile_wt", "n_cores", "pc", "px_height", "px_width", "ram", "sc_h", "sc_w", "talk_time"]]

# Calcula a média e o desvio padrão para as colunas selecionadas
column_stats = selected_columns.agg(['mean', 'std'])

# Calcula a soma da média e do desvio padrão
sum_of_mean_and_std = column_stats.sum()

# Exibe a soma da média e do desvio padrão
print(sum_of_mean_and_std)
```

Figura 16 - Código média + desvio

MÍNIMO E MÁXIMO

```
# Função para calcular e exibir o intervalo mínimo e máximo
def display_min_max(column):
    min_val = column.min()
    max_val = column.max()
    print(f'Coluna: {column.name}\nMínimo: {min_val}\nMáximo: {max_val}\n')

# Calcula e exibe o intervalo mínimo e máximo para todas as colunas selecionadas
for col in selected_columns.columns:
    display_min_max(selected_columns[col])
```

Figura 17- Código mínimo e máximo

MODA E MEDIANA

```
# Função para calcular e exibir a moda e a mediana
def display_mode_median(column):
    mode_val = column.mode().iloc[0]
    median_val = column.median()
    print(f'Coluna: {column.name}\nModa: {mode_val}\nMediana: {median_val}\n')

# Calcula e exibe a moda e a mediana para todas as colunas selecionadas
for col in selected_columns.columns:
    display_mode_median(selected_columns[col])
```

Figura 18- Código moda e mediana

PERCENTIS

```
import plotly.graph_objects as go
import pandas as pd

# Lista de percentis desejados
percentis = [25, 50, 75]

# Calcula os percentis para as colunas selecionadas
column_percentiles = selected_columns.agg(lambda x: x.quantile([p/100 for p in percentis]))

# Cria um gráfico de linhas interativo usando o Plotly
fig = go.Figure()

# Cores diferentes para cada percentil
colors = ['red', 'green', 'blue']

# Adiciona linhas para cada percentil
for i, p in enumerate(percentis):
    fig.add_trace(go.Scatter(x=column_percentiles.columns, y=column_percentiles.loc[p/100],
                             mode='lines+markers', name=f'Percentil {p}', line=dict(color=colors[i])))

# Adiciona rótulos e título
fig.update_layout(xaxis_title='Colunas', yaxis_title='Valores', title='Percentis')

# Exibe o gráfico interativo
fig.show()
```

Figura 19- Código percentis

HISTOGRAMA

```
df.loc[(df['price_range'] ==0), 'price_range'] = 'Preço baixo'
df.loc[(df['price_range'] ==1), 'price_range'] = 'Preço médio'
df.loc[(df['price_range'] ==2), 'price_range'] = 'Preço alto'
df.loc[(df['price_range'] ==3), 'price_range'] = 'Preço muito alto'

df.head()
```

Figura 20 - Código de substituição dos valores numéricos por categorias descritivas na coluna 'price_range'

```
selected_columns = df[["blue", "dual_sim", "four_g", "three_g", "touch_screen", "wifi", "price_range"]]
print(selected_columns.to_string(index=False))
```

Figura 21 - Seleção dos campos categóricos do DataFrame 'df'

```
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

# Definir uma paleta de cores
palette = sns.color_palette("husl", n_colors=len(selected_columns.columns[:-1]))

# Mapear cores para as colunas do DataFrame
color_map = {}
for i, col in enumerate(selected_columns.columns[:-1]):
    color_map[col] = palette[i]

# Configurar para facilitar a visualização
sns.set(style="whitegrid")
plt.figure(figsize=(15, 8))

# Loop através das categorias de preço
for i, price_category in enumerate(df['price_range'].unique(), 1):
    # Criar um subplot para cada categoria de preço
    plt.subplot(2, 2, i)

    # Filtrar o DataFrame para a categoria de preço atual
    subset_df = df[df['price_range'] == price_category]

    # Calcular a percentagem de preços em relação ao total
    total_values = subset_df[selected_columns.columns[:-1]].count()
    data_percentages = (subset_df[selected_columns.columns[:-1]] == 1).sum() / total_values * 100

    # Ordenar as colunas do maior para o menor
    data_percentages = data_percentages[data_percentages > 0].sort_values(ascending=False)

    # Criar um gráfico de barras para os preços com cores diferentes
    for col, percentage in data_percentages.items():
        plt.bar(col, percentage, color=color_map[col])

    # Adicionar rótulos e título
    plt.title(f'Distribuição para {price_category}')
    plt.xlabel('Características')
    plt.ylabel('Percentagem (%)')

# Ajustar o layout
plt.tight_layout()
plt.show()
```

Figura 22- Criar um conjunto de gráficos de barras que representam a distribuição dos preços em diferentes categorias de preço de um DataFrame

HEATMAP

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
d = pd.read_csv("train.csv")

# Increase the size of the heatmap.
plt.figure(figsize=(16, 6))
# Store heatmap object in a variable to easily access it when you want to include more features (such as title).
# Set the range of values to be displayed on the colormap from -1 to 1, and set the annotation to True to display the correlation values on the heatmap.
heatmap = sns.heatmap(d.corr(), vmin=-1, vmax=1, annot=True, cmap='viridis')
# Give a title to the heatmap. Pad defines the distance of the title from the top of the heatmap.
heatmap.set_title('Correlation Heatmap', fontdict={'fontsize':12}, pad=12);
```

Figura 23- Código do HeatMap

OUTLIERS

```
import pandas as pd

# Supondo que você tenha carregado seu DataFrame 'df' com os dados

# Lista das colunas de interesse
columns_of_interest = [ 'fc','px_height' ]

# Dicionário para armazenar os outliers por coluna
outliers = {}

# Loop sobre as colunas de interesse
for column in columns_of_interest:
    Q1 = df[column].quantile(0.25)
    Q3 = df[column].quantile(0.75)
    IQR = Q3 - Q1

    # Identificar outliers
    outliers[column] = df[(df[column] < Q1 - 1.5 * IQR) | (df[column] > Q3 + 1.5 * IQR)][column]

# Exibir os valores dos outliers por coluna
for column, values in outliers.items():
    print(f"Outliers na coluna '{column}':")
    print(values)
    print("\n")
```

Figura 24 - Código dos Outliers

CENÁRIO 1

	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memory	m_dep	mobile_wt	n_cores	...	px_height	px_width	ram	sc_h	sc_w	talk_time	three_g	touch_screen	wifi	price
0	1843	1	1.8	1	13	1	16	0.7	134	6	...	118	580	3213	15	14	15	1	1	0	
1	1424	0	0.5	1	16	1	23	0.6	80	4	...	1399	1663	1053	14	11	16	1	1	1	
2	1844	1	2.3	1	1	0	51	0.7	158	8	...	533	882	1724	5	1	14	0	1	1	
3	1501	0	1.1	0	12	1	2	0.2	187	1	...	198	1056	2487	13	12	16	1	1	1	
4	1976	1	2.6	1	6	0	45	1.0	136	4	...	652	1933	2470	11	1	3	0	0	0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1595	712	1	1.6	0	6	1	9	0.8	172	2	...	881	1234	3612	13	5	4	1	0	0	
1596	1664	1	2.9	1	9	1	15	0.5	177	7	...	1178	1929	1968	12	7	9	1	0	0	
1597	1375	1	1.1	0	3	1	9	0.9	145	7	...	475	726	3869	19	18	10	1	1	1	
1598	1910	1	1.7	0	0	0	34	0.6	115	2	...	985	1284	309	8	4	10	0	0	1	
1599	831	1	0.7	0	2	1	62	0.7	134	8	...	1482	1490	2573	16	12	18	1	0	1	
1600 rows × 21 columns																					

Figura 25- Cenário 1

CENÁRIO 2

```
selected_columns = d[[ "battery_power", "price_range", "px_height", "px_width", "ram" ]]
print(selected_columns.to_string(index=False))
```

battery_power	price_range	px_height	px_width	ram
1843	3	118	580	3213
1424	1	1399	1663	1053
1844	1	533	882	1724
1501	2	198	1056	2487
1976	3	652	1933	2470
1270	3	299	845	3770
1487	2	857	989	2003
1864	2	225	1545	2258
1307	1	897	1103	1412
1285	1	475	500	2094
715	2	21	562	3709
966	2	1446	1754	2574
689	0	487	722	1241
1218	1	1122	1746	1667
873	0	1257	1411	575
1834	3	0	1987	3692
1367	0	36	642	299
722	1	138	1371	2359
1953	2	555	764	2334
977	3	1502	1862	3714
879	0	403	1105	349
1900	1	912	1596	850
1504	2	507	973	2806
825	3	206	1917	3278
...				
1664	2	1178	1929	1968
1375	3	475	726	3869
1910	0	985	1284	309
831	2	1482	1490	2573

Figura 26- Cenário 2

CENÁRIO 3

```
import pandas as pd

# Valores específicos dos outliers
outliers_fc = [18, 18, 18, 18, 18, 17, 18, 18, 18, 17, 17, 18]
outliers_px_height = [1960, 1949]

# Encontrar índices das linhas que contêm esses outliers
indices_outliers_fc = d[d['fc'].isin(outliers_fc)].index
indices_outliers_px_height = d[d['px_height'].isin(outliers_px_height)].index

# Combinar todos os índices de outliers
indices_outliers = set(indices_outliers_fc) | set(indices_outliers_px_height)

# Remover as linhas que contêm os outliers identificados
df_cleaned = d.drop(indices_outliers)
```

Figura 27- Cenário 3

CENÁRIO 4

```
selected_columns = d[[ "battery_power", "price_range","px_height","px_width","ram" ]]
print(selected_columns.to_string(index=False))
```

battery_power	price_range	px_height	px_width	ram
1843	3	118	580	3213
1424	1	1399	1663	1053
1844	1	533	882	1724
1501	2	198	1056	2487
1976	3	652	1933	2470
1270	3	299	845	3770
1487	2	857	989	2003
1864	2	225	1545	2258
1307	1	897	1103	1412
1285	1	475	500	2094
715	2	21	562	3709
966	2	1446	1754	2574
689	0	487	722	1241
1218	1	1122	1746	1667
873	0	1257	1411	575
1834	3	0	1987	3692
1367	0	36	642	299
722	1	138	1371	2359
1953	2	555	764	2334
977	3	1502	1862	3714
879	0	403	1105	349
1900	1	912	1596	850
1504	2	507	973	2806
825	3	206	1917	3278
...				
1664	2	1178	1929	1968
1375	3	475	726	3869
1910	0	985	1284	309
831	2	1482	1490	2573

Figura 28- Cenário 4

CONSTRUÇÃO DOS MODELOS EM RAPIDMINER



Figura 29 - Modelação de Random Forest com a técnica de validação Cross-Validation




Figura 30- Modelação de Decision Treen com a técnica de validação Cross-Validation




Figura 31 - Modelação de Redes neuronais com a técnica de validação Cross-Validation




Figura 32 - Modelação de Naive Bayes com a técnica de validação Cross-Validation




Figura 33 - Modelação de SVM com a técnica de validação Cross-Validation

ÁRVORE DE DECISÃO DE CADA CENÁRIO




Figura 34 - Árvore de decisão do cenário 1




Figura 35- Árvore de decisão do cenário 2




Figura 36- Árvore de decisão do cenário 3




Figura 37- Árvore de decisão do cenário 4